Scrapyd 常用功能与 API

上一个小节中，我们学会了如何将项目打包并部署，这一节我们来熟悉 Scrapyd 的常用功能以及学习如何通过 Scrapyd 提供的 API 对爬虫发起指令。

Scrapyd-web

Scrapyd 官方文档中有介绍，Scrapyd 为使用者提供了 Web 与 JSON 两种访问方式，其中 `web` 用于监视运行进程和爬虫日志、`json` 用于向爬虫发送操作指令。

Web 中有首页、Jobs、Logs 三个主要页面：

- 首页：服务入口，展示已部署的项目名称
- Jobs：爬虫运行状态及运行记录的主要观察页面
- Logs：爬虫运行日志文本文件资源目录

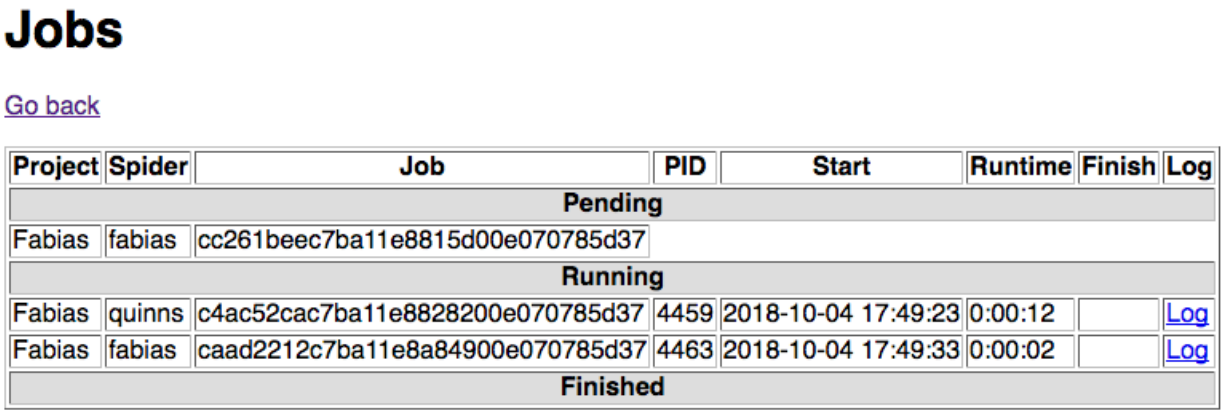

Jobs

Go back

Project	Spider	Job	PID	Start	Runtime	Finish	Log
Pending							
Fabias	fabias	cc261beec7ba11e8815d00e070785d37					
Running							
Fabias	quinns	c4ac52cac7ba11e8828200e070785d37	4459	2018-10-04 17:49:23	0:00:12		Log
Fabias	fabias	caad2212c7ba11e8a84900e070785d37	4463	2018-10-04 17:49:33	0:00:02		Log
Finished							

由上图可以看到，Jobs 页面中包含了爬虫与运行记录、项目名称、爬虫名称、jobID、进程 ID、启动时间、运行时长、结束时间以及日志链接。根据以上信息，我们可以对爬虫的状态做个大致的了解。

Scrapyd-json

Scrapyd 为使用者提供了很多的 API，在文档中称为资源。

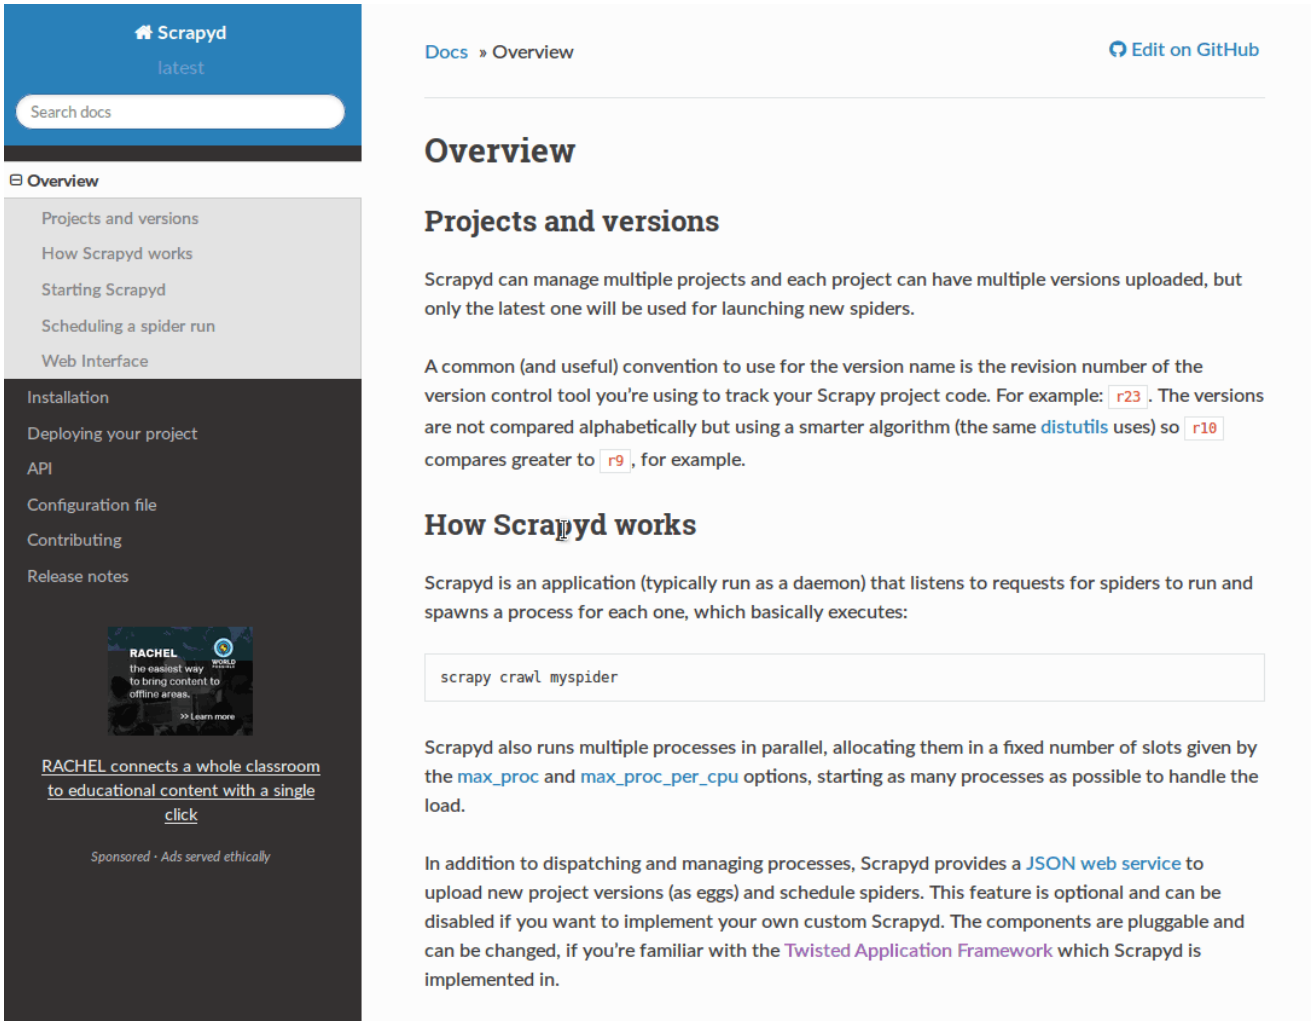

API 的作用介绍

API 的具体内容、用法和返回信息在官方文档中都有详尽的介绍，这里我做个归纳：

- daemonstatus.json - 用以检查 Scrapyd 服务的爬虫状态及对应数量。
- addversion.json - 用以为项目添加版本，如果项目不存在则创建项目。
- schedule.json - 用以启动指定的爬虫。
- cancel.json - 用以取消指定的爬虫。
- listprojects.json - 用以查看当前已部署的项目名称。
- listversions.json - 用以查看指定项目的版本号。
- listspiders.json - 用以查看指定项目的爬虫名称。
- listjobs.json - 用以查看指定项目下爬虫的运行状态。
- delversion.json - 用以删除指定项目的指定版本，如版本不存在则将项目删除。
- delproject.json - 用以删除指定项目及其已上传的所有版本。

API 的使用示例

官方示例中以 cURL 作为请求工具，向服务的 API 发起请求

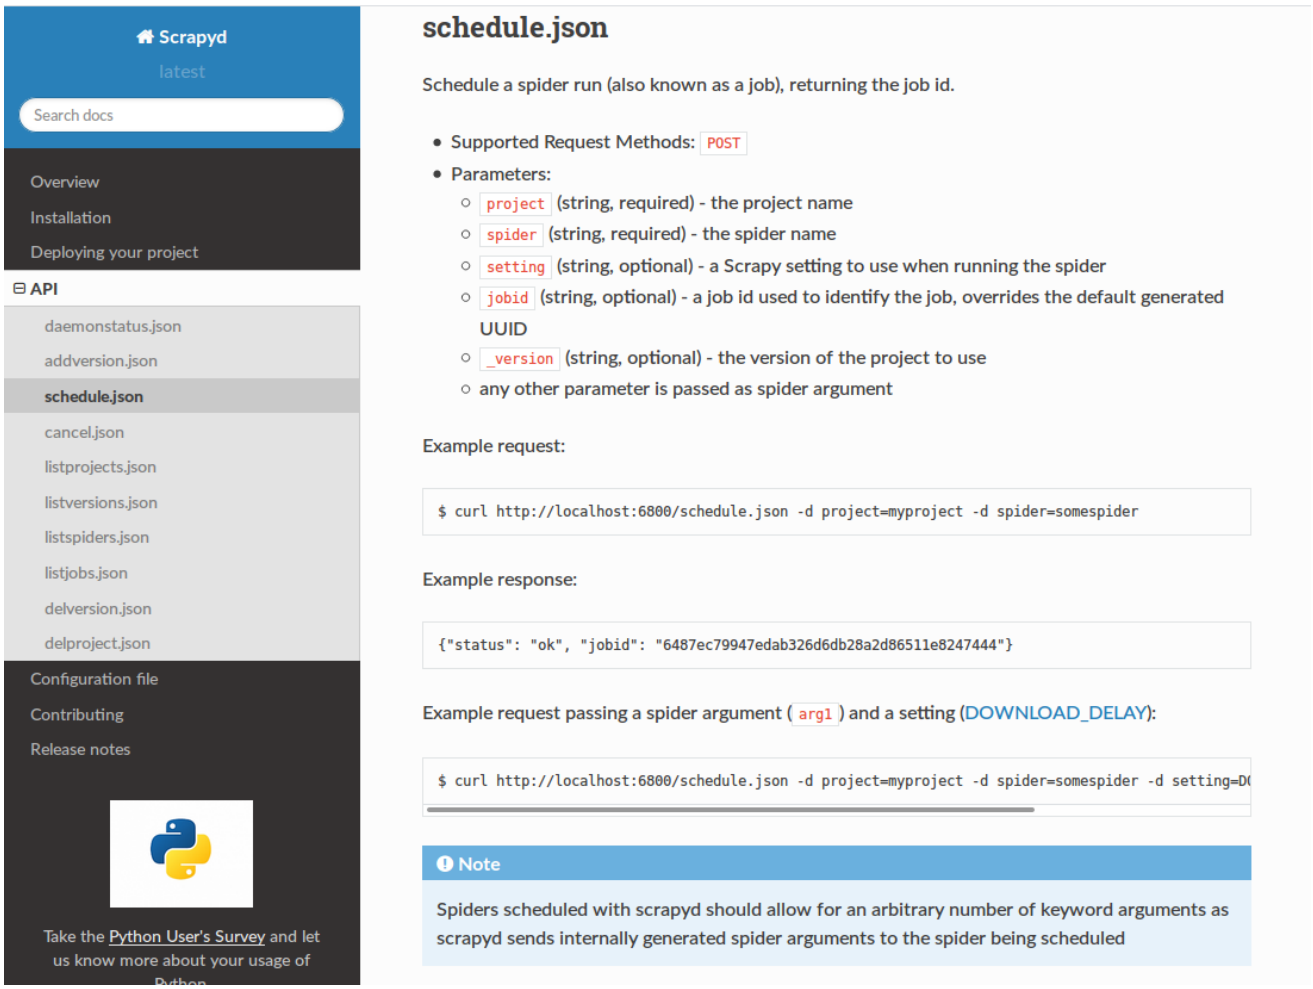

如启动指定爬虫：

```
$ curl http://localhost:6800/schedule.json -d project=myproject -d spider=somespider

```

当然，如果你想在启动的时候传递指定的参数，也可以这么写：

```
$ curl http://localhost:6800/schedule.json -d project=myproject -d spider=somespider  -d arg1=val1

```

官方返回示例为：

```
{"status": "ok", "jobid": "6487ec79947edab326d6db28a2d86511e8247444"}

```

cURL 动图演示：

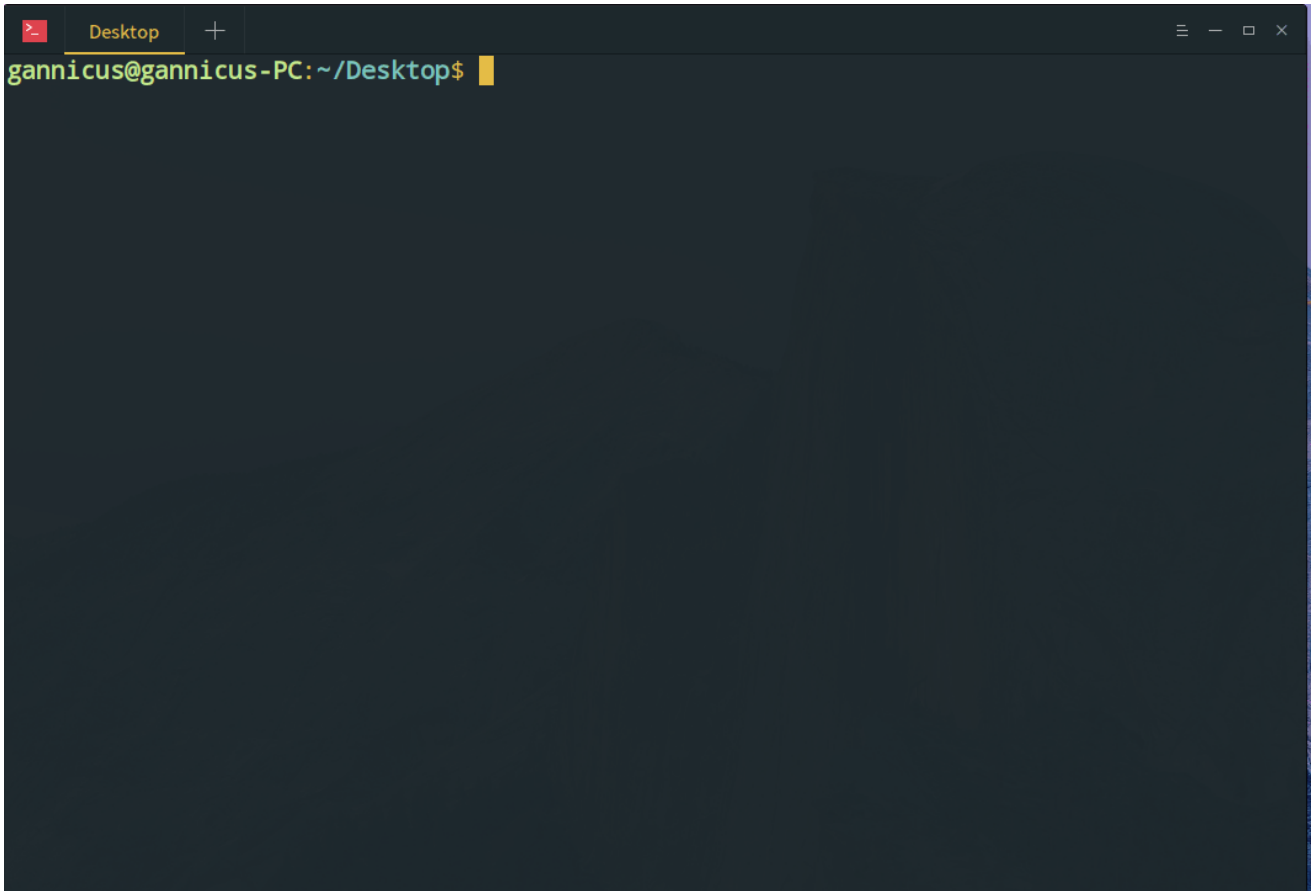

使用 Postman 工具启动爬虫

当然，除了官方推荐的 cURL，我们还可以使用 Postman 来作为我们的请求工具，同样是启动指定的爬虫，Postman 的设置如下所示：

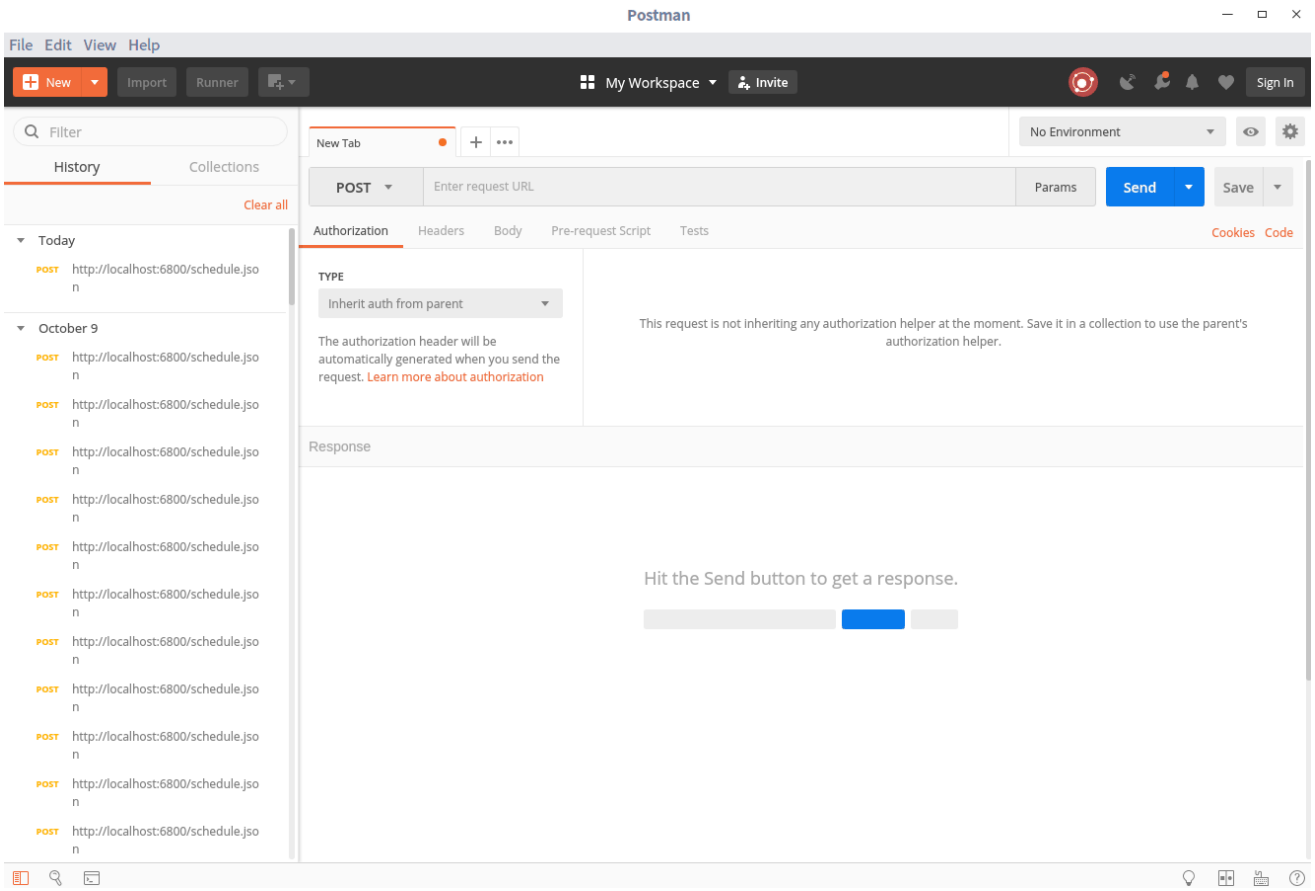

设置好请求地址和对应的参数后，点击 Send 发送请求，我们就会得到 Scrapyd 中 Schedule 视图类提供的返回结果：

```
{
    "node_name": "node-name",
    "status": "ok",
    "jobid": "ede04d0ac7be11e8b70d00e070785d37"
}

```

代表此次请求发送成功且能够启动对应的爬虫。

使用 Python 代码启动爬虫

既然它是通过网络请求来发送指令，那我们就可以使用 requests 来模拟请求的发起，新建 `sendapi.py` 文件并敲写代码：

```
import requests


url = "http://localhost:6800/schedule.json"
params = {"project": "arts", "spider": "tips"}
resp = requests.post(url, data=params)
print(resp.text)

```

通过命令`python sendapi.py`运行得到返回结果：

```
{"node_name": "gannicus-PC", "status": "ok", "jobid": "51bdd2bad1ac11e89ed954ee75c0e204"}

```

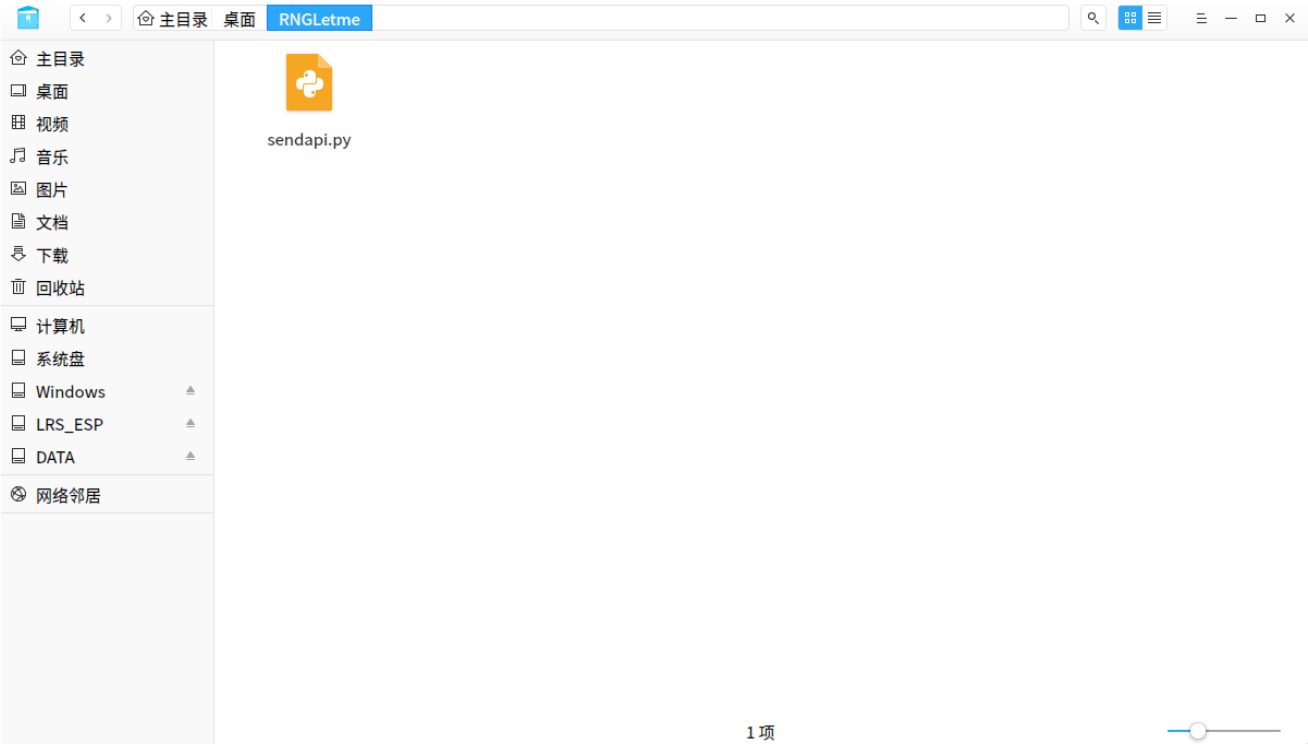

Scrapyd 日志

爬虫的运行信息都会记录在日志文件当中，在 Jobs 页面，可以找到爬虫任务对应的日志，也可以通过 Logs 查看某个项目或某个爬虫的日志，日志内容如下图所示：

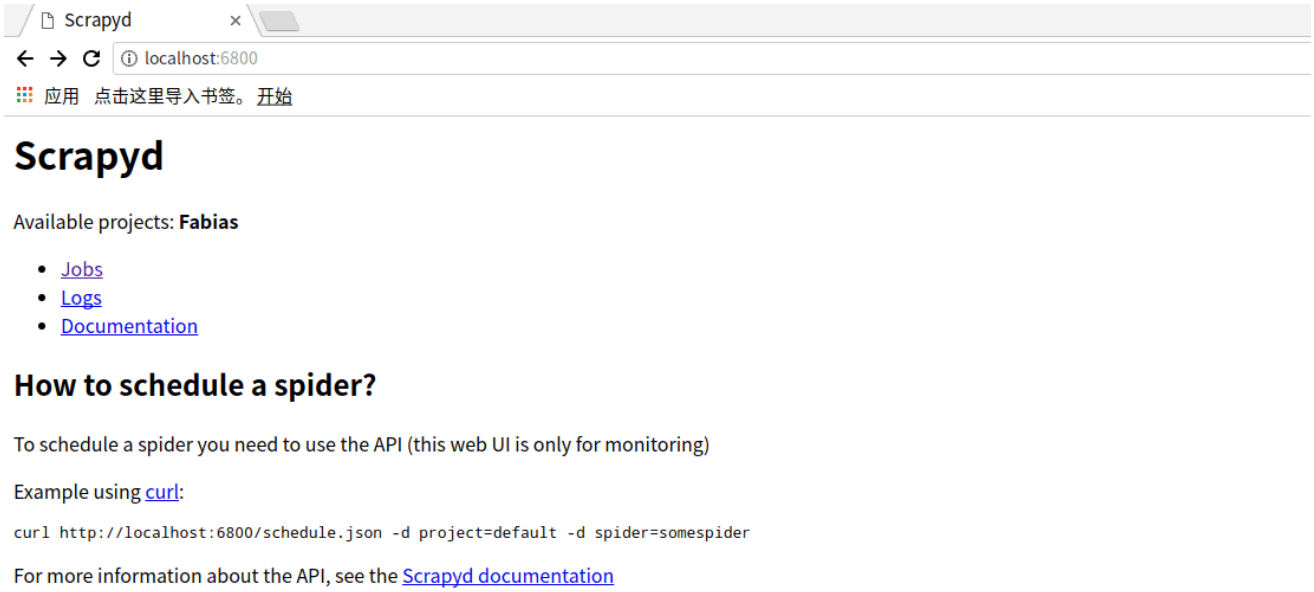

小结

本小节结合 Scrapyd 文档与示例代码，我们了解到 Scrapyd API 的用法，并且通过网络请求工具 Postman 发起请求，最后使用 Python 代码向 Scrapyd 服务发起请求，成功启动指定爬虫，完成了从文档到实践的跳跃。